Data Science Interview Copilot
Guia de Preparação para Entrevistas Técnicas

Público-Alvo

Cientistas de Dados Júnior e Engenheiros de Machine Learning Júnior.

Objetivo

Destilar a documentação oficial e a literatura acadêmica para fornecer respostas precisas e matematicamente rigorosas sobre métricas, validação e interpretabilidade.

Regra de Ouro: A precisão conceitual e a compreensão dos limites matemáticos de cada método superam a simples memorização de código.

Gemini Notebook

Fundamentos de Classificação

Matriz de Confusão

Verdadeiros Positivos (TP)
Predição correta da classe positiva.

Falsos Positivos (FP)
Predição incorreta da classe positiva (Erro Tipo I).

Falsos Negativos (FN)
Predição incorreta da classe negativa (Erro Tipo II).

Verdadeiros Negativos (TN)
Verdadeiros Negativos e Recall.

(Ignorado na Precisão e Recall).

Precision (Precisão)

$$\text{Precision} = \frac{TP}{TP + FP}$$

Proporção de predições positivas corretas. Útil quando o **custo do Falso Positivo é alto** (ex: bloqueio de transação legítima).

Recall (Revocação)

$$\text{Recall} = \frac{TP}{TP + FN}$$

Proporção de positivos reais identificados. Útil quando o custo do Falso Negativo é crítico (ex: diagnóstico médico).

F1-Score

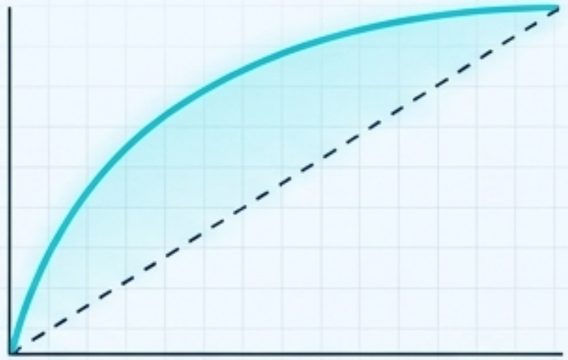
$$F1 = 2 * \frac{(\text{Precision} * \text{Recall})}{(\text{Precision} + \text{Recall})}$$

Média harmônica entre Precisão e Recall. Penaliza assimetrias extremas entre as métricas.

Gemini Notebook

Avaliação sob Desbalanceamento: ROC-AUC vs. PR-AUC

ROC-AUC (Receiver Operating Characteristic)



- **Eixos: Taxa de Verdadeiros Positivos (TPR)** vs. **Taxa de Falsos Positivos (FPR)**.
- **Baseline:** Linha diagonal (0.5), independente da distribuição de classes.
- **Comportamento:** Avalia ranqueamento global. Otimista sob forte desbalanceamento, pois o denominador do FPR cresce massivamente com os Verdadeiros Negativos,

PR-AUC (Precision-Recall Area Under Curve)



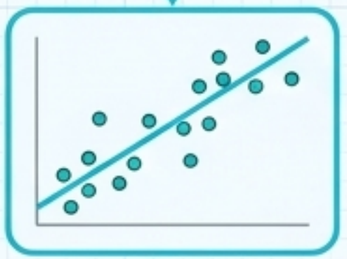
- **Eixos: Precision** vs. **Recall**.
- **Baseline:** Linha horizontal **(Proporção da classe positiva)**.
- **Comportamento:** Ignora **Verdadeiros Negativos (TN)**. Foca estritamente na relação entre acertos (TP) e alarmes falsos (FP).

Dica de Entrevista: Não afirme que o ROC-AUC é inválido para dados desbalanceados. Ele apenas responde a uma pergunta diferente (ranqueamento global). O PR-AUC é mais informativo sobre a classe minoritária.

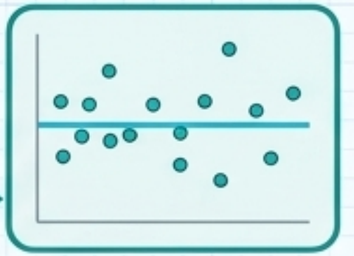
Gemini Notebook

Métricas de Regressão: R^2 e R^2 Ajustado

$$R^2 = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$$



Soma dos Quadrados dos Resíduos (Erro do Modelo)



Soma Total dos Quadrados (Variância Total)

Coeficiente de Determinação:
Mensura a proporção da variância de y explicada pelas variáveis independentes.

Pode o R^2 ser negativo?
Sim. Embora seja estritamente ≤ 1, o R^2 pode ser negativo em dados fora da amostra (out-of-sample). Ocorre quando o erro do modelo supera a variância em torno da média simples.

R^2 Ajustado:
Penaliza a inclusão de variáveis irrelevantes.

⚠ **Alerta:** Um aumento do R^2 no conjunto de treinamento não significa necessariamente melhoria na generalização.

Gemini Notebook

Integridade dos Dados: Evitando o Data Leakage

Data Leakage: Uso inadvertido de informações do teste durante a construção do modelo. Resulta em performance otimista na validação e falha em produção.

⚠️ Anti-Padrão: Pré-processamento Incorreto

```
1. Aplicar StandardScaler()
   em toda a base
```

→

```
2. Fazer train_test_split
```

→ **Erro**: A média e variância do conjunto de teste vazaram para o treinamento.

✅ Boa Prática: Isolamento com Pipelines

```
1. Fazer train_test_split
primeiro
```

→

```
2. Encapsular:
Pipeline([scaler, modelo])
```

→ **Acerto:** O `Pipeline` garante que o `fit()` ocorra estritamente no treino, aplicando apenas o `transform()` no teste.

Gemini Notebook

Validação Cruzada e Prevenção de Overfitting

Overfitting: Quando o modelo memoriza o ruído dos dados de treino, perdendo a capacidade de generalizar.



Cyan = Dados de Validação Navy = Dados de Treino

K-Fold: Divisão aleatória clássica para dados independentes.

Stratified K-Fold: Mantém a proporção das classes originais. Mandatório para dados desbalanceados.

TimeSeriesSplit: Janelas deslizantes que respeitam a ordem cronológica, prevenindo vazamento do futuro para o passado.

Estratégias de Prevenção: Regularização (L1/L2), poda de árvores (pruning), Early Stopping e coleta de mais dados.

Gemini Notebook

Reprodutibilidade e o Papel do `random_state`

O `random_state` fixa a semente inicial de um Gerador de Números **Pseudoaleatórios (PRNG)**.

⚠️ Mito

Ajustar o `random_state` previne overfitting.

✅ Fato

A semente apenas fixa uma trajetória determinística no espaço de busca (ex: inicialização de pesos). Não altera as propriedades teóricas de generalização do algoritmo.

⚠️ Mito

Fixar o `random_state` garante reprodutibilidade absoluta.

✅ Fato

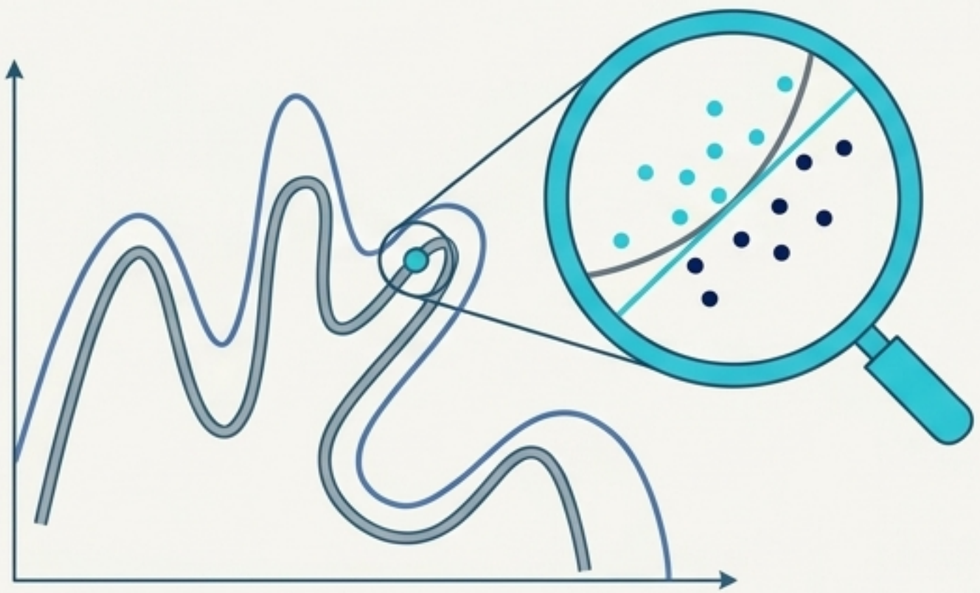
Diferenças de hardware, precisão de ponto flutuante, bibliotecas otimizadas e paralelismo em GPUs introduzem **não-determinismo** que a semente não controla.

Gemini Notebook

Interpretabilidade de Modelos: LIME e SHAP

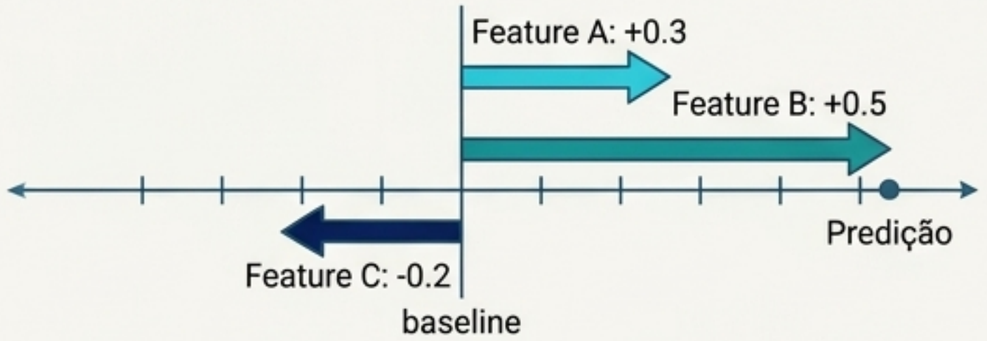
Global (dependência no modelo completo) vs. Local (justificativa de uma predição individual)

LIME (Local Interpretable Model-agnostic Explanations)



Perturba a amostra localmente e treina um modelo substituto (surrogate) interpretável para aproximar a fronteira de decisão daquela vizinhança restrita.

SHAP (SHapley Additive exPlanations)



Baseado na Teoria dos Jogos.

Valores SHAP representam a contribuição marginal de cada atributo em relação a um valor de referência (baseline) predito.

Atenção: Valores SHAP não são porcentagens e não demonstram causalidade no mundo real, apenas a associação aprendida pelo modelo.

Gemini Notebook

Sabatina: Simulado de Entrevista Técnica

`> Predizemos fraudes (1% da base). Acurácia é 99% e ROC-AUC é 0.95. Pronto para produção?`

Não necessariamente. A **Acurácia** é ilusória (prever tudo como '0' dá 99%). O **ROC-AUC** pode estar inflando a percepção devido à massa de Falsos Positivos mascarada por Verdadeiros Negativos massivos. Exige-se análise de **PR-AUC e F1-Score**.

`> O R² no conjunto de teste resultou em -0.50. Isso é um erro de código?`

Não. Significa que, fora da amostra, **o modelo obteve um erro quadrático maior do que a simples predição da média constante dos dados.**

`> Como aplicar Oversampling (ex: SMOTE) sem causar Data Leakage?`

O Oversampling deve **ocorrer estritamente dentro do loop de validação cruzada, apenas nas partições de treino (encapsulado via `Pipeline`). Se feito antes do split, amostras sintéticas vazarão para o teste.**

Gemini Notebook

Conclusões e Referências

Conclusões (Takeaways)

- A escolha da métrica dita o comportamento em produção: otimize para o custo real do erro.
- O vazamento de dados é resolvido estruturalmente, não manualmente (use sempre Pipelines).
- O domínio da matemática subjacente evita armadilhas conceituais sobre R^2, interpretação SHAP e PRNGs.

Dependências Oficiais

```
scikit-learn 1.9.1 Docs:
  - Common pitfalls
  - Metrics and scoring

Saito & Rehmsmeier (2015):
  - Precision-Recall vs ROC Plot

Kaufman et al. (2012):
  - Leakage in Data Mining

Interpretable ML:
  - Teoria dos Jogos e SHAP
```

Gemini Notebook